

FIAP – FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO PAULISTA

Curso de Engenharia de Software

Alvaro Matos — RM 553751

Christian Gonzaga — RM 553775

Filipe Oliveira — RM 552906

Isabela Barcellos — RM 553746

AGROVISION

Relatório Técnico — Protótipo de Visão Computacional para Classificação de Folhas de
Tomateiro no Agronegócio (Projeto AgroSmart)

São Paulo – SP

2026

Alvaro Matos — RM 553751
Christian Gonzaga — RM 553775
Filipe Oliveira — RM 552906
Isabela Barcellos — RM 553746

AGROVISION

Relatório Técnico — Protótipo de Visão Computacional para Classificação de Folhas de Tomateiro no Agronegócio (Projeto AgroSmart)

Relatório técnico apresentado como requisito de avaliação da fase de Visão Computacional do projeto integrador multidisciplinar AgroSmart, referente às atividades desenvolvidas no conjunto das disciplinas do semestre do curso de Engenharia de Software da FIAP.

São Paulo – SP
2026

RESUMO

Este relatório documenta o desenvolvimento do protótipo AgroVision, elaborado na fase de Visão Computacional do projeto integrador AgroSmart, cujo objetivo é a transformação digital do agronegócio brasileiro por meio de tecnologias como visão computacional, automação, inteligência artificial, análise de dados e computação em nuvem. O protótipo classifica folhas de tomateiro em duas categorias — "Saudável" e "Doente" — a partir de imagens reais de um banco de dados público, utilizando técnicas de processamento de imagem com OpenCV (extração de histogramas de cor no espaço HSV) e um classificador Random Forest treinado com a biblioteca Scikit-learn. A aplicação foi disponibilizada em uma interface web construída com Streamlit, permitindo o upload de imagens, a visualização do resultado da classificação com o respectivo grau de confiança e a exportação dos dados em formato CSV e JSON. Nos testes realizados, o modelo atingiu acurácia de 97,5% sobre o conjunto de teste. Discute-se, por fim, a aplicabilidade da solução no monitoramento fitossanitário de lavouras e seu papel como etapa inicial de um sistema mais amplo de apoio à produção rural baseado em dados.

Palavras-chave: Visão Computacional. Agronegócio. Classificação de Imagens. Aprendizado de Máquina. AgroSmart.

SUMÁRIO

1 INTRODUÇÃO.....	3
2 OBJETIVOS.....	3
2.1 Objetivo geral.....	3
2.2 Objetivos específicos.....	3
3 DESENVOLVIMENTO.....	4
3.1 Tecnologias utilizadas.....	4
3.2 Base de imagens (dataset).....	4
3.3 Extração de características.....	5
3.4 Treinamento do modelo de classificação.....	6
3.5 Aplicação web (interface de uso).....	6
3.6 Exportação de dados.....	6
4 RESULTADOS.....	7
4.1 Desempenho do modelo.....	7
4.2 Exemplos de classificação.....	7
4.3 Exportação dos dados (CSV/JSON).....	8
5 APLICABILIDADE NO AGRONEGÓCIO.....	8
6 CONSIDERAÇÕES FINAIS.....	9
REFERÊNCIAS.....	9

1 INTRODUÇÃO

O agronegócio brasileiro é um dos pilares da economia nacional, e sua modernização por meio de tecnologias digitais tem se mostrado essencial para o aumento da produtividade, a redução de perdas e o uso mais eficiente dos recursos naturais. O projeto AgroSmart propõe justamente essa transformação, integrando, em fases, tecnologias como visão computacional, automação, inteligência artificial, análise de dados e computação em nuvem em uma solução completa de apoio à produção rural baseada em dados.

Nesta primeira fase do projeto, o grupo aplicou conceitos de Visão Computacional para desenvolver o protótipo AgroVision, um sistema capaz de identificar, a partir de imagens de folhas de tomateiro, se a planta se encontra em estado saudável ou apresenta sinais de doença. A escolha da cultura do tomate se justifica pela disponibilidade de bases de imagens públicas de qualidade e pela relevância econômica da cultura, frequentemente acometida por doenças foliares como a pinta-preta (*Alternaria solani*), que podem comprometer significativamente a produtividade quando não identificadas e tratadas a tempo.

Este documento apresenta o relatório técnico referente à etapa 1.3 da atividade avaliativa, descrevendo o processo de desenvolvimento do protótipo, as tecnologias utilizadas, os resultados obtidos e a aplicabilidade da solução no contexto do agronegócio.

2 OBJETIVOS

2.1 Objetivo geral

Desenvolver um protótipo funcional de reconhecimento de imagens capaz de classificar folhas de tomateiro como "Saudável" ou "Doente", utilizando técnicas acessíveis de Visão Computacional, com exportação estruturada dos resultados obtidos.

2.2 Objetivos específicos

- Construir uma base de imagens rotuladas de folhas saudáveis e doentes para treinamento e teste do classificador;
- Extrair características visuais relevantes das imagens (histogramas de cor) que permitam diferenciar folhas saudáveis de folhas doentes;
- Treinar e avaliar um modelo de aprendizado de máquina supervisionado para a tarefa de classificação binária;
- Disponibilizar uma interface web simples para upload de imagens e visualização dos resultados em tempo real;

- Implementar a exportação dos resultados da classificação nos formatos CSV e JSON;
- Discutir a aplicabilidade da solução no monitoramento fitossanitário do agronegócio.

3 DESENVOLVIMENTO

Nesta seção descreve-se o processo de desenvolvimento do protótipo AgroVision, contemplando a organização da base de imagens, a etapa de extração de características, o treinamento do modelo de classificação, a interface de uso e a exportação dos dados gerados.

3.1 Tecnologias utilizadas

O protótipo foi desenvolvido inteiramente em Python, combinando bibliotecas de visão computacional, aprendizado de máquina e construção de interfaces web, conforme resumido no Quadro 1.

Quadro 1 – Tecnologias utilizadas no desenvolvimento do protótipo.

Tecnologia	Finalidade no projeto
Python 3	Linguagem de programação principal do protótipo.
OpenCV (cv2)	Leitura, redimensionamento, conversão de espaço de cor e extração de histogramas das imagens.
NumPy	Manipulação vetorial dos histogramas de características.
Scikit-learn	Treinamento, validação e uso do classificador Random Forest.
Joblib	Serialização (.pkl) e carregamento do modelo treinado.
Streamlit	Construção da interface web interativa da aplicação.

Fonte: Elaborado pelos autores (2026), com base no requirements.txt do projeto.

3.2 Base de imagens (dataset)

Para o treinamento e a avaliação do classificador, foi utilizada uma base de imagens reais de folhas de tomateiro, organizada em duas pastas: "saudavel" e "doente". As imagens foram extraídas do PlantVillage Dataset (MOHANTY; HUGHES; SALATHÉ, 2016), um repositório público de imagens de folhas saudáveis e doentes que abrange 14 espécies de cultivo e 26 doenças. As imagens de folhas doentes utilizadas neste protótipo correspondem à classe de pinta-preta (Early Blight), doença fúngica comum na cultura do tomate, causada pelo fungo *Alternaria solani*. A Tabela 1 apresenta a composição da base utilizada.

Tabela 1 – Composição da base de imagens utilizada no treinamento.

Categoria	Quantidade de imagens
-----------	-----------------------

Saudável	100
Doente (pinta-preta)	100
Total	200

Fonte: Elaborado pelos autores (2026).

A Figura 1 apresenta exemplos de folhas saudáveis presentes na base, enquanto a Figura 2 apresenta exemplos de folhas com sinais da doença.



Figura 1 – Exemplos de folhas saudáveis da base de imagens.

Fonte: Mohanty, Hughes e Salathé (2016) — base de imagens PlantVillage.



Figura 2 – Exemplos de folhas doentes (pinta-preta) da base de imagens.

Fonte: Mohanty, Hughes e Salathé (2016) — base de imagens PlantVillage.

3.3 Extração de características (pré-processamento e visão computacional)

Antes de serem apresentadas ao classificador, as imagens passam por uma etapa de pré-processamento implementada com a biblioteca OpenCV. Cada imagem é redimensionada para 128x128 pixels, garantindo um vetor de características de tamanho fixo independentemente da resolução original. Em seguida, a imagem é convertida do espaço de cor RGB para o espaço HSV (matiz, saturação e valor), mais robusto a variações de iluminação do que o RGB tradicional.

Para cada um dos três canais HSV, é calculado um histograma de 32 posições, normalizado entre 0 e 1. Os três histogramas (matiz, saturação e valor) são concatenados em um

único vetor de 96 posições, que representa numericamente a distribuição de cores da folha analisada. Como folhas doentes costumam apresentar manchas de coloração distinta (tons amarronzados e amarelados) em relação a folhas saudáveis (predominantemente verdes), essa representação baseada em histograma de cor mostrou-se suficiente para diferenciar as duas classes com boa precisão, conforme apresentado na Seção 4.

3.4 Treinamento do modelo de classificação

Com os vetores de características extraídos das 200 imagens da base (100 saudáveis e 100 doentes), foi realizada a divisão dos dados em conjunto de treino e conjunto de teste, na proporção de 80% para treino e 20% para teste, de forma estratificada por classe, garantindo a mesma proporção de exemplos saudáveis e doentes em ambos os conjuntos.

O algoritmo escolhido foi o Random Forest (floresta aleatória), um método de aprendizado supervisionado que combina múltiplas árvores de decisão treinadas sobre subconjuntos distintos dos dados, reduzindo o risco de sobreajuste e aumentando a robustez da classificação. Foi utilizada a implementação RandomForestClassifier da biblioteca Scikit-learn, configurada com 200 árvores de decisão (`n_estimators=200`). Após o treinamento, o modelo foi serializado em um arquivo `modelo_folhas.pkl` por meio da biblioteca Joblib, permitindo seu carregamento posterior pela aplicação sem necessidade de novo treinamento.

3.5 Aplicação web (interface de uso)

A interface de uso do protótipo foi construída com o framework Streamlit, que permite a criação de aplicações web interativas em Python sem a necessidade de desenvolvimento front-end tradicional. A aplicação (arquivo `app.py`) permite ao usuário selecionar uma ou mais imagens de folhas de tomateiro por meio de upload. Para cada imagem enviada, o sistema executa a mesma rotina de extração de características descrita na Seção 3.3 e submete o vetor resultante ao modelo previamente treinado, que retorna a classe prevista ("Saudável" ou "Doente") e a probabilidade associada à predição, exibida ao usuário como percentual de confiança.

Os resultados de cada imagem classificada são armazenados durante a sessão do usuário e exibidos em uma tabela na própria interface, junto de botões que permitem apagar o histórico de classificações ou exportar os resultados acumulados.

3.6 Exportação de dados

Conforme requisito da atividade, os resultados da classificação podem ser exportados em dois formatos estruturados, implementados no módulo `exportar_dados.py`:

- CSV: arquivo delimitado por ponto e vírgula, contendo as colunas nome_imagem, categoria e acuracia, com codificação UTF-8 (BOM) para compatibilidade com o Microsoft Excel;
- JSON: arquivo estruturado contendo a data e hora de geração, o total de imagens classificadas e a lista detalhada de resultados, no mesmo padrão de campos do CSV.

Um exemplo do conteúdo exportado é apresentado na Seção 4.3.

4 RESULTADOS

4.1 Desempenho do modelo

O modelo foi avaliado sobre o conjunto de teste (20% da base, 40 imagens, mantendo a proporção entre classes), atingindo acurácia geral de 97,5%. A Tabela 2 detalha as métricas de precisão, revocação e F1-score obtidas para cada classe.

Tabela 2 – Métricas de desempenho do classificador no conjunto de teste.

Classe	Precisão	Revocação	F1-score
Saudável	1,00	0,95	0,97
Doente	0,95	1,00	0,98
Acurácia geral			0,975

Fonte: Elaborado pelos autores (2026), a partir da saída do script treinar_modelo.py.

Os resultados indicam que o modelo classificou corretamente todas as folhas saudáveis apresentadas no teste (revocação de 0,95) com pequena margem de erro, e identificou corretamente todas as ocorrências de doença (revocação de 1,00), o que é desejável em um cenário de monitoramento fitossanitário, no qual deixar de identificar uma planta doente (falso negativo) tende a ser mais custoso do que um alarme falso.

4.2 Exemplos de classificação

A Tabela 3 apresenta exemplos reais de classificação obtidos ao submeter imagens da base ao modelo treinado, exibindo a categoria prevista e o grau de confiança (probabilidade máxima retornada pelo modelo) para cada imagem.

Tabela 3 – Exemplos de resultados de classificação gerados pelo protótipo.

Imagem (nome de arquivo)	Categoria prevista	Confiança do modelo
...RS_HL 9940.JPG	Saudável	100,00%
...RS_HL 0063.JPG	Saudável	98,50%

...RS_HL 0555.JPG	Saudável	90,50%
...Erly.B 7778.JPG	Doente	91,00%
...Erly.B 9499.JPG	Doente	94,00%
...Erly.B 7572.JPG	Doente	98,00%

Fonte: Elaborado pelos autores (2026), a partir da execução do modelo sobre imagens da base.

4.3 Exportação dos dados (CSV/JSON)

A seguir, um trecho real do arquivo CSV gerado pela aplicação a partir de um conjunto de imagens classificadas:

```
nome_imagem;categoria;acuracia
...HL 9940.JPG;Saudável;100.0%
...Erly.B 7778.JPG;Doente;91.0%
```

O mesmo conjunto de resultados, exportado em formato JSON, segue a estrutura abaixo:

```
{
  "gerado_em": "2026-08-22 12:42:25",
  "total_imagens": 2,
  "resultados": [
    {"nome_imagem": "...HL 9940.JPG", "categoria": "Saudável", "acuracia":
"100.0%"},
    {"nome_imagem": "...Erly.B 7778.JPG", "categoria": "Doente",
"acuracia": "91.0%"}
  ]
}
```

Fonte: Elaborado pelos autores (2026), a partir da saída real do módulo exportar_dados.py.

5 APLICABILIDADE NO AGRONEGÓCIO

A identificação precoce de doenças em lavouras é um dos principais desafios do manejo fitossanitário, especialmente em propriedades de médio e grande porte, nas quais a inspeção visual manual de cada planta é inviável em escala. Soluções de visão computacional como o AgroVision podem apoiar produtores e agrônomos na triagem inicial de folhas, reduzindo o tempo de diagnóstico e permitindo intervenções mais rápidas, como a aplicação direcionada de defensivos agrícolas apenas nas áreas afetadas.

No contexto do projeto AgroSmart, este protótipo representa a camada de percepção do sistema: a capacidade de "enxergar" o campo e transformar imagens em dados estruturados (categoria e confiança), que poderão futuramente alimentar as camadas de automação, análise de dados e computação em nuvem previstas nas próximas fases do projeto. Entre as aplicações práticas da solução, destacam-se:

- Monitoramento periódico de talhões por meio de imagens capturadas via smartphone ou drones;
- Geração de alertas automáticos quando a proporção de folhas doentes identificadas ultrapassar um limiar definido pelo produtor;
- Registro histórico da sanidade da lavoura ao longo do tempo, a partir dos dados exportados em CSV/JSON;
- Redução do uso de defensivos agrícolas, ao direcionar a aplicação apenas às áreas com sinais de doença identificados pelo sistema.

6 CONSIDERAÇÕES FINAIS

O protótipo AgroVision demonstrou ser possível construir, com ferramentas acessíveis e de código aberto, um sistema funcional de classificação de imagens capaz de diferenciar folhas saudáveis de folhas doentes com alta acurácia (97,5% no conjunto de teste), cumprindo os requisitos estabelecidos para esta fase do projeto AgroSmart: protótipo funcional de reconhecimento de imagens, exportação de dados em CSV/JSON e documentação técnica do processo.

Como limitações do protótipo, destacam-se o uso de um conjunto de dados relativamente pequeno (200 imagens) e restrito a uma única cultura (tomateiro) e a um único tipo de doença (pinta-preta), além da dependência de características de cor, que podem ser sensíveis a variações de iluminação, ângulo e qualidade da fotografia em ambientes de campo reais, diferentemente das condições controladas do banco de imagens utilizado. Como trabalhos futuros, sugere-se a ampliação da base de dados para outras culturas e doenças, a avaliação de modelos baseados em redes neurais convolucionais e a integração do protótipo às demais camadas do projeto AgroSmart, como automação e computação em nuvem, permitindo o processamento de imagens em escala e em tempo real.

REFERÊNCIAS

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. NBR 14724: informação e documentação: trabalhos acadêmicos: apresentação. Rio de Janeiro: ABNT, 2011.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. NBR 6022: informação e documentação: artigo em publicação periódica científica impressa: apresentação. Rio de Janeiro: ABNT, 2018.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. NBR 6023: informação e documentação: referências: elaboração. Rio de Janeiro: ABNT, 2018.

BRADSKI, G. The OpenCV Library. Dr. Dobb's Journal of Software Tools, 2000.

PEDREGOSA, F. et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.

STREAMLIT INC. Streamlit documentation. Disponível em: <https://docs.streamlit.io>. Acesso em: 22 ago. 2026.

MOHANTY, S. P.; HUGHES, D. P.; SALATHÉ, M. Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, v. 7, art. 1419, 2016. DOI: 10.3389/fpls.2016.01419. Base de imagens disponível em: <https://github.com/spMohanty/PlantVillage-Dataset>. Acesso em: 22 ago. 2026.